

# LAB.-5—BASE-DE-DATOS-IRIS-04-09-25.R

angel

2025-11-26

```
#####
# LAB. 5 - BASE DE DATOS IRIS - TAREA HW_02
# FLOR ANGELI CRUZ ROSALES
# DR. MARCO A. GONZALEZ TAGLE
# 04/09/25
#####

# La base de datos iris es uno de los conjuntos de datos más utilizados en
# estadística y aprendizaje automático

# El conjunto contiene 150 observaciones correspondientes a tres especies de iris
# (setosa, versicolor y virginica), con 50 muestras por especie.

# Para cada flor se registran cuatro variables cuantitativas:
# Sepal.Length: longitud del sépalo (cm)
# Sepal.Width: ancho del sépalo (cm)
# Petal.Length: longitud del pétalo (cm)
# Petal.Width: ancho del pétalo (cm)

# Explorar la base de datos iris usando funciones como head(), summary()
data("iris")
head(iris)

##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1         5.1       3.5        1.4       0.2  setosa
## 2         4.9       3.0        1.4       0.2  setosa
## 3         4.7       3.2        1.3       0.2  setosa
## 4         4.6       3.1        1.5       0.2  setosa
## 5         5.0       3.6        1.4       0.2  setosa
## 6         5.4       3.9        1.7       0.4  setosa

str(iris)

## 'data.frame': 150 obs. of 5 variables:
## $ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
## $ Sepal.Width : num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
## $ Petal.Length: num 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
## $ Petal.Width : num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
## $ Species     : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ...
```

```
summary(iris)

##   Sepal.Length   Sepal.Width   Petal.Length   Petal.Width
##   Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
##   1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
##   Median :5.800   Median :3.000   Median :4.350   Median :1.300
##   Mean   :5.843   Mean   :3.057   Mean   :4.358   Mean   :1.399
##   3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
##   Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
##
##          Species
##  setosa      :50
##  versicolor:50
##  virginica :50
##
##
```

*# Identificar las variables Petal.Length y determina las estadísticas descriptivas para las dos especies*

```
data_sub <- subset(iris, Species %in% c("versicolor", "virginica"))
head(data_sub)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width   Species
## 51       7.0      3.2       4.7      1.4 versicolor
## 52       6.4      3.2       4.5      1.5 versicolor
## 53       6.9      3.1       4.9      1.5 versicolor
## 54       5.5      2.3       4.0      1.3 versicolor
## 55       6.5      2.8       4.6      1.5 versicolor
## 56       5.7      2.8       4.5      1.3 versicolor
```

```
table(data_sub$Species)
```

```
##
##      setosa versicolor virginica
##          0        50        50
```

*# Función tapply para obtener promedio*

```
tapply(data_sub$Petal.Length, data_sub$Species, mean)
```

```
##      setosa versicolor virginica
##          NA        4.260      5.552
```

*# Setosa versicolor virginica*  
*# NA 4.260 5.552*  
*# Los pétalos de virginica son más largos 1.3cm más*

*# Función tapply para obtener desviación estándar*

```
tapply(data_sub$Petal.Length, data_sub$Species, sd)
```

```

##      setosa versicolor virginica
##      NA 0.4699110 0.5518947

# Setosa versicolor virginica
# NA 0.4699110 0.5518947

# Función tapply para obtener varianza
tapply(data_sub$Petal.Length, data_sub$Species, var)

##      setosa versicolor virginica
##      NA 0.2208163 0.3045878

# Setosa versicolor virginica
# NA 0.2208163 0.3045878
# Mayor variabilidad en la especie virginica

summary(data_sub$Petal.Length)

##      Min. 1st Qu. Median      Mean 3rd Qu.      Max.
##      3.000   4.375   4.900   4.906   5.525   6.900

tapply(data_sub$Petal.Length, data_sub$Species, summary)

## $setosa
## NULL
##
## $versicolor
##      Min. 1st Qu. Median      Mean 3rd Qu.      Max.
##      3.00   4.00   4.35   4.26   4.60   5.10
##
## $virginica
##      Min. 1st Qu. Median      Mean 3rd Qu.      Max.
##      4.500  5.100  5.550  5.552  5.875  6.900

# Defina una pregunta de investigación sobre la variable Petal.Length
# Pregunta: ¿Hay una diferencia en la longitud de los pétalos entre las especies versicolor y virginica

# Si hay una diferencia en la longitud de los pétalos, para obtener información
# más confiable si realizamos una prueba de t student

# Separar los datos por especie usando subset

df_versicolor <- subset(iris, Species == "versicolor")
df_virginica<- subset(iris, Species == "virginica")

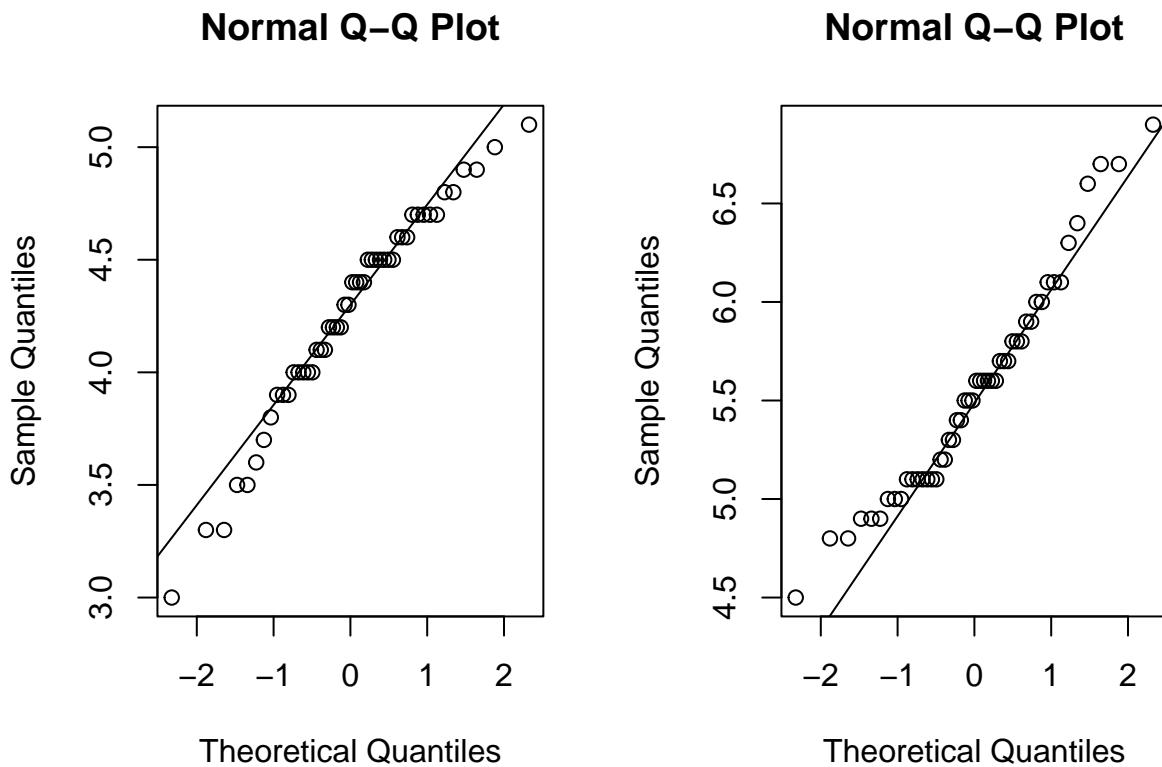
# qqnorm es un gráfico que nos ayudará a revisar la normalidad de los datos

# Función para que la ventana de gráficas permita que nos
# aparezca dos gráficos par(mfrow)

```

```
# Una fila con dos columnas (1,2)

par(mfrow=c(1,2))
qqnorm(df_versicolor$Petal.Length); qqline(df_versicolor$Petal.Length)
qqnorm(df_virginica$Petal.Length); qqline(df_virginica$Petal.Length)
```



```
# El gráfico muestra que una normalidad en nuestros datos ya que
# en la mayoría los puntos están muy cercanos a la linea recta

# Pero podemos verificarlo de manera más precisa realizando una prueba de Shapiro-Wilks

shapiro.test(df_versicolor$Petal.Length)

##
##  Shapiro-Wilk normality test
##
## data: df_versicolor$Petal.Length
## W = 0.966, p-value = 0.1585

# data: df_versicolor$Petal.Length
# W = 0.966, p-value = 0.1585

shapiro.test(df_virginica$Petal.Length)
```

```

##  

## Shapiro-Wilk normality test  

##  

## data: df_virginica$Petal.Length  

## W = 0.96219, p-value = 0.1098

# data: df_virginica$Petal.Length  

# W = 0.96219, p-value = 0.1098

# *Los resultados son mayores a p-value 0.05, por lo que se acepta la normalidad*  

# Cumple con uno de los tres criterios para realizar la prueba de t student

# Revisar homogeneidad de varianzas (segundo criterio)
var.test(Petal.Length ~ Species, data= subset(iris, Species %in% c("versicolor", "virginica")))

##  

## F test to compare two variances  

##  

## data: Petal.Length by Species  

## F = 0.72497, num df = 49, denom df = 49, p-value = 0.2637  

## alternative hypothesis: true ratio of variances is not equal to 1  

## 95 percent confidence interval:  

## 0.411402 1.277530  

## sample estimates:  

## ratio of variances  

## 0.7249678

# El resultado es un p-value= 0.2637 lo que nos indica un valor mayor  

# a p-value=0.05, por lo que no se rechaza mi hipótesis nula  

# Hay homogeneidad de varianzas pues se toman como iguales

# Se cumplen con los 3 criterios necesarios para realizar una prueba de t-student

iris_sub <- subset(iris,Species %in% c("versicolor", "virginica"))
t.test(Petal.Length ~ Species, data= iris_sub,
       var.equal = TRUE)

##  

## Two Sample t-test  

##  

## data: Petal.Length by Species  

## t = -12.604, df = 98, p-value < 2.2e-16  

## alternative hypothesis: true difference in means between group versicolor and group virginica is not  

## 95 percent confidence interval:  

## -1.495426 -1.088574  

## sample estimates:  

## mean in group versicolor mean in group virginica  

## 4.260 5.552

```

```

# Resultados= t = -12.604, valor negativo que nos indica que hay una diferencia grande
# entre las medias
# p-value < 2.2e-16 , valor pequeño y menor a p-value= 0.05 por lo que
# se rechaza la hipótesis nula (H0)

# Intervalo de confianza
# -1.495426 -1.088574

# Diferencia de las medias: 4.260 - 5.552
#[1]-1.292

# La diferencia esta fuera del intervalo de confianza, lo que
# nos confirma que es una hipótesis alternativa
# Si no entra en el intervalo de confianza es H1 (alternativa)
# Si esta dentro del intervalo es H0 (nula)

# Se puede afirmar que los pétalos de la especie virginica son más largos
# que los de la especie versicolor
# Se acepta la hipótesis alternativa que nos indica que si existe diferencia en la
# longitud de los pétalos entre las especies versicolor y virginica

# Se determina con el Tamaño de efecto (Cohen's)

cohens_efecto <- function(x,y) {
  n1 <- length(x); n2 <- length(y)
  s1 <- sd(x); s2 <- sd(y)
  sp <- sqrt((n1-1)* s1^2 + (n2-1)* s2^2)/(n1+n2 - 2))
  (mean(x)- mean(y))/sp
}

d_cal <- cohens_efecto(df_virginica$Petal.Length, df_versicolor$Petal.Length)
cohens_efecto(df_virginica$Petal.Length, df_versicolor$Petal.Length)

## [1] 2.520756

# 2.520756 es mayor al rango de 1.3, por lo que se puede deducir que la
# diferencia en la longitud del pétalo es estadísticamente significativa
# y relevante

#Visualización: boxplot que muestra las diferencias entre especies

library(ggplot2)

## Warning: package 'ggplot2' was built under R version 4.5.2

ggplot(iris_sub, aes(x = Species, y = Petal.Length, fill = Species)) +
  geom_boxplot() +
  labs(title = "Comparación de Petal.Length entre especies",
       x = "Especie",
       y = "Longitud del Pétalo (cm)")

```

### Comparación de Petal.Length entre especies

